

Contents

1	我叫gemini給我架構而已	2
2	緒論	2
2.1	研究動機	2
2.2	研究目的	2
3	資料描述與探索性分析(Data Description & EDA)	2
3.1	資料集概況(Data Description)	2
3.2	探索性資料分析(EDA)	2
4	資料處理與特徵工程	2
4.1	資料處理與轉換	2
5	研究方法	3
5.1	階層式預測架構	3
5.2	模型選擇	3
6	結果分析	3
6.1	因為特徵高度相關預期變數選擇lasso與降維PCA要有不錯的表現	3
7	這舊的=Model result compare*****	4
8	最終討論與結論	4
8.1	整體模型表現比較	4
8.2	重要觀察結果	4
8.2.1	類別不平衡問題	4
8.2.2	Bias-Variance 權衡	5
8.3	各模型分析	5
8.4	最終結論	5
8.5	總結性觀察	5

Abstract

本研究旨在運用統計機器學習方法，針對NBA 常規賽數據建立預測模型，以評估球隊進入分區決賽之競爭力。透過整合1996 至2023 年之傳統與進階數據，我們比較了Ridge/Lasso 邏輯回歸、隨機森林、梯度提升樹及類神經網路等多種模型。研究結果顯示，基於球隊實力機率的排序模型能有效預測季後賽晉級趨勢，並在單一系列賽的勝負預測中展現良好之鑑別度。

1 我叫gemini給我架構而已

2 緒論

2.1 研究動機

NBA 賽事具備高度競爭性，賽況受到球隊體系、球員狀態等多重變數影響。利用過去20 年之數據累積，透過數據驅動之方法論來量化球隊實力，對於理解現代籃球的勝負關鍵具有學術價值。

2.2 研究目的

1. 構建球隊晉級分區決賽之競爭力預測模型。2. 比較不同機器學習模型在時間序列交叉驗證(TimeSeriesSplit) 下的預測效能。3. 實作系列賽勝負模擬函數，並評估其準確度。

3 資料描述與探索性分析(Data Description & EDA)

3.1 資料集概況(Data Description)

本研究使用之NBA 資料集包含常規賽(RS) 與季後賽(PO) 數據，涵蓋1996 至2023 賽季。資料集整合了兩大維度：

- **傳統數據(Traditional Stats)**：包含勝率(W/L%)、得失分、籃板、助攻、失誤等，反映球隊在球場上的基本輸出能力。
- **進階數據(Advanced Stats)**：包含節奏(Pace)、淨效率值(Net Rating)、有效命中率(eFG%) 等，用以消除比賽節奏差異，更精準地評估球隊效能。

3.2 探索性資料分析(EDA)

為了釐清變數間的關聯性並處理潛在的多重共線性問題，我們執行了以下EDA 程序：

1. **變數分佈分析**：利用直方圖檢查各項統計指標（如每場得分、Net Rating）的分佈狀況，識別是否存在偏態。
2. **相關性矩陣(Correlation Heatmap)**：計算各特徵間的Pearson 相關係數。我們發現「勝率」與「淨效率值(Net Rating)」呈現高度正相關，後續處理中將進行適當的特徵處理，以避免邏輯回歸模型產生過度配適。
3. **類別不平衡探討**：分析「是否進入分區決賽」之目標變數，發現樣本中晉級球隊（標籤1）佔少數，因此在模型訓練時導入`class_weight='balanced'` 參數以進行校正。

4 資料處理與特徵工程

4.1 資料處理與轉換

我們將Response 設定為是否進入分區決賽(*is_conf_finalist*)，並解決以下技術細節：

- **數據標準化**：使用StandardScaler 確保各模型（尤其是Logistic Regression）能穩定收斂。
- **特徵選取**：排除Rank 類指標以避免資料洩漏(Data Leakage)，保留進階指標如Pace 與Net Rating。

5 研究方法

5.1 階層式預測架構

本研究不直接預測二元標籤，而是輸出晉級機率 $P(Advance = 1|X)$ 。

$$P(SeriesAwin) = \frac{P_A}{P_A + P_B}$$

5.2 模型選擇

1. **正規化模型**：Ridge (L_2) 與Lasso (L_1) 邏輯回歸。
2. **集成學習**：Random Forest 與Gradient Boosting Classifier，用以捕捉非線性之特徵互動。
3. **驗證機制**：考量數據的時間相依性，採用TimeSeriesSplit 以避免訓練集覆蓋測試集未來之數據。

6 結果分析

6.1 因為特徵高度相關預期變數選擇lasso與降維PCA要有不錯的表現

本研究透過混淆矩陣(Confusion Matrix) 與AUC-ROC 曲線評估模型。

- **分類效能**：透過設定 $threshold = 0.40$ ，在保留靈敏度(Recall) 的同時，平衡了偽陽性(FP) 的產生。
- **特徵重要性**：透過隨機森林模型，發現Net Rating 等進階指標為預測決賽競爭力的關鍵因素。

References

- [1] NBA Official Statistics, <https://www.nba.com/stats>.

7 這舊的=Model result compare*****

Table 1: 各模型於訓練集與測試集之分類表現

Model	Dataset	Accuracy	Precision	Recall	Specificity	F1-Score
Logistic Regression	Train	0.9260	0.7532	0.6824	0.9646	0.7160
	Test	0.8778	0.5556	0.4167	0.9487	0.4762
Lasso Logistic Regression	Train	0.9196	0.7536	0.6118	0.9683	0.6753
	Test	0.8611	0.4545	0.2083	0.9615	0.2857
Random Forest	Train	0.9743	0.9367	0.8706	0.9907	0.9024
	Test	0.8833	0.6000	0.3750	0.9615	0.4615
Gradient Boosting Machine	Train	0.9904	0.9759	0.9529	0.9963	0.9643
	Test	0.7778	0.3333	0.6667	0.7949	0.4444
PCA + Logistic Regression	Train	0.8971	0.6667	0.4941	0.9609	0.5676
	Test	0.8944	0.6667	0.4167	0.9679	0.5128
MLP Neural Network	Train	1.0000	1.0000	1.0000	1.0000	1.0000
	Test	0.8833	0.5789	0.4583	0.9487	0.5116

Recall = Sensitivity.

所有指標越高代表模型表現越佳，但在不平衡資料下應優先關注Precision、Recall 與F1-Score。

8 最終討論與結論

8.1 整體模型表現比較

本研究比較多種統計與機器學習模型於NBA 季後賽晉級預測之表現。整體而言，各模型在訓練集上皆呈現良好擬合能力，但在測試集上皆出現不同程度的性能下降，顯示模型存在明顯的bias-variance trade-off 問題。

表2 彙整各模型在測試集上的表現結果。

Table 2: 各模型測試集表現比較

模型	Accuracy	F1-score	Precision	Recall
邏輯斯迴歸(Baseline)	0.8778	0.4762	0.5556	0.4167
Lasso 邏輯斯迴歸	0.8611	0.2857	0.4545	0.2083
隨機森林	0.8833	0.4615	0.6000	0.3750
梯度提升樹(GBM)	0.7778	0.4444	0.3333	0.6667
PCA + 邏輯斯迴歸	0.8944	0.5128	0.6667	0.4167
類神經網路(MLP)	0.8833	0.5116	0.5789	0.4583

8.2 重要觀察結果

8.2.1 類別不平衡問題

所有模型皆呈現相似現象：特異度 (Specificity) 較高，但召回率 (Recall) 偏低。這表示模型傾向預測「未晉級」類別，反映季後賽資料本身存在明顯的類別不平衡問題。

8.2.2 Bias-Variance 權衡

從結果可觀察到明顯的bias-variance trade-off：

- 邏輯斯迴歸與Lasso 模型：偏向高偏差（underfitting），模型較為簡單。
- 隨機森林與GBM：能捕捉非線性關係，但存在較高變異性。
- 類神經網路：訓練集表現極佳，但測試集顯示過度擬合現象。
- PCA + 邏輯斯迴歸：在偏差與變異之間取得最佳平衡。

8.3 各模型分析

邏輯斯迴歸（Baseline） 基準模型表現穩定，但受限於線性假設，無法捕捉球隊之間的非線性互動關係，因此整體表現有限。

Lasso 邏輯斯迴歸 由於L1 正則化導致過度稀疏化，使部分重要特徵被壓縮至接近0，造成資訊損失，進而導致召回率下降。

隨機森林 能有效捕捉非線性特徵交互關係，且泛化能力相對穩定，但對跨球季資料的外推能力仍有限。

梯度提升樹（GBM） 在訓練集上表現極佳，但測試集表現明顯下降，顯示模型存在過度擬合問題，對資料噪音較為敏感。

PCA + 邏輯斯迴歸 本模型於測試集上表現最佳。主成分分析有效降低特徵共線性與維度冗餘，使模型能學習較穩定的整體結構，提升泛化能力。

類神經網路（MLP） 模型在訓練集上達到完美擬合，顯示高度過度擬合現象，但仍因具備非線性表示能力，在測試集上維持不錯表現。

8.4 最終結論

整體而言，本研究顯示NBA 季後賽預測問題受到以下限制：

- 季後賽資料存在明顯類別不平衡問題
- 不同賽季之間存在分佈轉移（concept drift）
- 傳統數據特徵無法完整描述球隊真實競爭力

在所有模型中，PCA 結合邏輯斯迴歸提供最佳且最穩定的預測表現，顯示在高度共線性與噪音資料環境下，降維技術對提升泛化能力具有關鍵作用。

非線性模型（如隨機森林與GBM）雖然具備較強表達能力，但在資料量有限且具高度不確定性的情境下，容易產生過度擬合問題。

8.5 總結性觀察

本研究結果顯示，在NBA 季後賽預測問題中，模型的「簡單性+ 適當特徵轉換」往往比高度複雜的機器學習模型更具實用性，尤其在資料有限且分佈不穩定的情境下更為明顯。